

# CHAINES DE MARKOV ET MODÉLISATION

KAMIL STOS

N° CANDIDAT: 54417

JUIN 2022



FIG. 1 – *Andrei Markov*



FIG. 2 – *Paul Ehrenfest*




FIG. 3 – *Mouvement Brownien*

# Qu'est ce qu'une chaine de Markov ?

- Espace probabilisé  $(\Omega, \mathcal{F}, p)$
- $\{X_n\}_{n \geq 0}$  une suite de v.a. à valeur dans un ensemble  $Q = \{i_1, \dots, i_n\}$

## Propriété de Markov

$\forall (i_0, \dots, i_n) \in Q^{n+1} :$

$$P(X_{n+1} = i_{n+1} | X_n = i_n, \dots, X_0 = i_0) = P(X_{n+1} = i_{n+1} | X_n = i_n)$$

# Exemple





FIG. 4 – Exemple d'une chaîne de Markov : point de vue automate



## Matrice de transition

$$\forall (i,j) \in \llbracket 1,n \rrbracket^2 : \quad A_{i,j} = P(X_{n+1} = i_{n+1} | X_n = i_n)$$

## Matrice de transition de l'exemple précédent

$$A = \begin{pmatrix} 0.7 & 0.3 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 \\ 0 & 0 & 0.1 & 0.9 & 0 \\ 0.8 & 0 & 0 & 0 & 0.2 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

## Utilité

Position initiale:  $\pi = \left( P(X_0 = i_1), P(X_0 = i_2), \dots, P(X_0 = i_n) \right)$

Après p itérations:  $\pi \times A^p = \left( P(X_p = i_1), P(X_p = i_2), \dots, P(X_p = i_n) \right)$

Position initiale:  $\pi = \left( P(X_0 = i_1), P(X_0 = i_2), \dots, P(X_0 = i_n) \right)$


Après p itérations:  $\pi \times A^p = \left( P(X_p = i_1), P(X_p = i_2), \dots, P(X_p = i_n) \right)$

- Est ce que le système converge vers une distribution stationnaire ?
- Si oui quelle est la configuration finale ?



# Système à deux états

- $Q = \{u_0, u_1\}$
- $\exists p, q \in ]0,1[, \quad A = \begin{pmatrix} 1-p & p \\ q & 1-q \end{pmatrix}$



$$A = \begin{pmatrix} 1-p & p \\ q & 1-q \end{pmatrix}$$

$\chi_A = \det(XI_2 - A) = X^2 + (p + q - 2)X + (1 - p - q)$  est scindé à racines simples dans  $\mathbb{R}$ .

A possède deux valeurs propres 1 et  $1 - p - q$ :  $A \simeq \begin{pmatrix} 1 & 0 \\ 0 & 1 - p - q \end{pmatrix}$

et alors on a  $\lim_{n \rightarrow +\infty} A^n = \frac{1}{(p+q)} \begin{pmatrix} q & p \\ q & p \end{pmatrix}$

Probabilité d'infection:

$$\frac{\text{moyenne de cas actifs}}{\text{population}}$$

Probabilité de guérison:

$$\frac{\text{Morts} + \text{COVID long}}{\text{nombre de cas}}$$






FIG. 5 – *Modèle à deux états*

Même démarche mais plus d'états:





● Nombre de cas par semaine pour 100 000 habitants

FIG. 6 – Nombre d'infectés en France ([gouvernement.fr](https://gouvernement.fr))

# Jeux d'argent, probabilité de ruine

- Deux joueurs à position symétrique



# Jeux d'argent, probabilité de ruine

- Deux joueurs à position symétrique
- N pièces :  $Q = \llbracket 0; 2N \rrbracket$
-



# Jeux d'argent, probabilité de ruine

- Deux joueurs à position symétrique
- $N$  pièces :  $Q = \llbracket 0; 2N \rrbracket$
- $X_n$  : argent de A à la  $n^{ieme}$  partie

# Jeux d'argent, probabilité de ruine

- Deux joueurs à position symétrique
- $N$  pièces:  $Q = \llbracket 0; 2N \rrbracket$
- $X_n$ : argent de A à la  $n^{ieme}$  partie

Par exemple pour  $N = 2$ ,

$$A = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 1-p & 0 & p & 0 \\ 0 & 1-p & 0 & p \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

$$\text{On note } u_i = P\left(\exists t \in \mathbb{N} : X_t = 0 \mid X_0 = i\right)$$

puis

$$u_i = pu_{i+1} + (1-p)u_{i-1} = p u_i + (1-p) u_i$$

d'où

$$(u_{i+1} - u_i) = \frac{1-p}{p}(u_i - u_{i-1})$$

$$u_i = \sum_{k=0}^{i-1} \left( \frac{1-p}{p} \right)^k (u_1 - u_0) + u_0$$

- Si  $p = \frac{1}{2}$  :

$$u_i = 1 - \frac{i}{N}$$

- Sinon :

$$u_i = 1 - \frac{1 - \left(\frac{1-p}{p}\right)^i}{1 - \left(\frac{1-p}{p}\right)^N}$$

Contre un casino:  $N \rightarrow +\infty$  et

- Si  $p \leq \frac{1}{2}$  :  $u_i = 1$




FIG. 7 – cas  $p = 0.3$

- Sinon,  $u_i = \left(\frac{1-p}{p}\right)^i$




FIG. 8 – cas  $p = 0.5001$

## Espérance du temps d'une partie

On note  $T_i$  la variable aléatoire t.q.

$$(T_i = n) = \left( X_n = 0 \text{ ou } 2N \text{ et } \forall 0 < k < n : X_k \neq 0 \text{ ou } N \mid X_0 = i \right)$$

avec  $v_i = \mathbb{E}(T_i)$  :

$$\forall i \in \llbracket 1; N-1 \rrbracket, \quad v_i = pv_{i+1} + (1-p)v_{i-1} + 1$$

Par la même méthode:

$$v_{i+1} = \frac{i}{2p-1} + \left(v_1 - \frac{1}{2p-1}\right) \times \frac{1 - \left(\frac{1-p}{p}\right)^i}{1 - \left(\frac{1-p}{p}\right)^N}$$

•  $p = \frac{1}{2}$  :

$$\forall i \in \llbracket 1; N-1 \rrbracket, \quad v_i = \frac{1}{2}v_{i+1} + \frac{1}{2}v_{i-1} + 1$$

puis  $v_k = k(N - k)$




FIG. 9 – *cas*  $p = 0.5$



# Distribution des temps d'arrivées




FIG. 10 – Distribution des temps d'arrivée pour  $p = 0.5$ ,  $N = 20$

# Distribution des temps d'arrivées




FIG. 11 – Distribution des temps d'arrivée pour  $p = 0.3$ ,  $N = 200$

# Distribution des temps d'arrivées




FIG. 12 – Distribution des temps d'arrivée pour  $p = 0.7$ ,  $N = 200$

# Classification d'états

## Etat récurrent

$i$  est **récurrent** si:

$$f_{ii} := P(\text{Retour à } i \mid X_0 = i) = 1$$

Il est **transient** dans le cas contraire.

## Etat récurrent positif

$i$  est dit **récurrent positif** s'il est récurrent et que

$$\mu_i = E\left(\min\{n \in \mathbb{N}^*, X_n = i\} \mid i_0 = i\right) \in \mathbb{R}^*$$

Il est dit **récurrent nul** si  $\mu_i = +\infty$

## Etat périodique

La **période** d'un état est:

$$d(i) = \begin{cases} \text{pgcd}\left(\{n \geq 1, A_{ii}^{(n)} > 0\}\right) & \text{si cet ensemble est non vide} \\ 0 & \text{sinon} \end{cases}$$

Si  $d(i) = 0$  ou  $d(i) = 1$ , l'état est **apériodique**

- Si  $A_{ii}^n > 0$  *APCR*,  $i$  est **apériodique**.
- Si  $i$  **apériodique**:  
Quand  $A_{ii}^n > 0$  et  $A_{ii}^m > 0$ , alors  $A_{ii}^{n+m} > 0$

$$\exists (n_1, \dots, n_k) \quad : \quad \forall i \in \llbracket 1, k \rrbracket, \quad A_{i,i}^{n_k} > 0$$

$$n_1\mathbb{Z} + \dots + n_k\mathbb{Z} = \mathbb{Z}$$

*puis*

$$\exists a \in \mathbb{N} \quad : \quad n_1\mathbb{N} + \dots + n_k\mathbb{N} = [a; \infty[$$

d'où  $A_{ii}^n > 0$  à partir du rang  $a$ .

## Etat ergodique

$i$  est **ergodique** s'il est récurrent positif et apériodique.

### Exemple

On considère une situation modélisée par la matrice suivante

$$P = \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{pmatrix}.$$

Alors on voit que l'état 1 est récurrent:

$$Pr(\text{Non retour à } 1 | i_0 = 1) = \prod_{n=1}^{+\infty} \frac{1}{2} = 0$$

Il est récurrent positif:

$$E(\min\{n \in \mathbb{N}^*, X_n = 1\} \mid X_0 = 1) = \sum_{k=1}^{+\infty} k \times \left(\frac{1}{2}\right)^k = 2$$

Il est apériodique:  $\forall n \in \mathbb{N}^*, P_{ii}^n > 0$

C'est finalement un état **ergodique**.

# Théorème principal

## Théorème ergodique

Pour  $j$  un état **ergodique**:

$$\lim_{n \rightarrow +\infty} P_{ij}^{(n)} = f_{ij} \times \frac{1}{\mu_j}$$

avec

$$\mu_i = E\left(\min\{n \in \mathbb{N}^*, X_n = i\} \mid i_0 = i\right) \in \mathbb{R}^*$$

et

$$f_{ij} = Pr(\text{Visite en } j \mid X_0 = i)$$



# Démonstration

- On a pour  $n \in \mathbb{N}^*$

$$A_{i,j}^{(n)} = \sum_{k=1}^n f_{ij}^{(k)} A_{j,j}^{(n-k)}$$

- $\sum_{k \geq 1} f_{ij}^{(k)}$  converge.

$$\underline{\text{Si}} \lim_{n \rightarrow \infty} \delta_{\{k \leq n\}} A_{j,j}^{(n-k)} = \lim_{n \rightarrow \infty} A_{j,j}^{(n)} = \frac{1}{\mu_j}$$

**Alors**

$$A_{i,j}^{(n)} = \sum_{k=1}^n f_{ij}^{(k)} A_{j,j}^{(n-k)} = \sum_{k=0}^{+\infty} f_{ij}^{(k)} A_{j,j}^{(n-k)} \delta_{\{k \leq n\}}$$

## Lemme

Si l'on a  $\lim_{n \rightarrow \infty} b_{n,k} = b$  pour tout  $k$  avec  $0 \leq b_{n,k} \leq 1$  et  $a_k \geq 0$ , alors

$$\lim_{n \rightarrow \infty} \sum_{k=1}^{+\infty} a_k b_{n,k} = b \sum_{k=1}^{+\infty} a_k$$

Par le lemme:

$$\sum_{k=0}^{+\infty} f_{ij}^{(k)} A_{j,j}^{(n-k)} \delta_{\{k \leq n\}} \xrightarrow{n \rightarrow +\infty} \left( \sum_{k=0}^{+\infty} f_{ij}^{(k)} \right) \times \lim_{n \rightarrow \infty} A_{j,j}^{(n-k)} = \frac{f_{i,j}}{\mu_j}$$

Montrons maintenant que

$$\lim_{n \rightarrow \infty} A_{j,j}^{(n)} = \frac{1}{\mu_j}$$

On appelle « équation de renouvellement » :

$$\sum_{k \geq 1} \delta_{\{k \leq n\}} A_{j,j}^{(n-k)} \times \left( \sum_{m \geq k} f_{j,j}^{(m)} \right) = 1$$

Soit  $\phi$  une *extractrice* telle que

$$A_{j,j}^{\phi(n)} \xrightarrow{n \rightarrow \infty} \ell$$

Montrons que  $\ell = \frac{1}{\mu_j}$

Prenons  $\psi$  une *extractrice* telle que  $A_{j,j}^{\psi(n)} \xrightarrow{n \rightarrow \infty} \ell'$ .

$$A_{j,j}^{\psi(n)} = \sum_{i \in Q} A_{j,i}^{(k)} A_{i,j}^{(n-k)} = \sum_{i \in Q} A_{j,i}^{(k)} (A_{i,j}^{(n-k)} - A_{j,j}^{(n-k)}) + \sum_{i \in Q} A_{j,i}^{(k)} A_{j,j}^{(n-k)}$$

On montre que pour  $i$  **communiquant avec  $j$** ,

$$A_{i,j}^{(n)} - A_{j,j}^{(n)} \xrightarrow{n \rightarrow \infty} 0$$

Par le lemme;

$$\ell = \ell' \sum_{i \in Q} A_{j,i}(k) = \ell'$$

*i.e.*  $\ell = \ell'$


On applique alors l'**équation de renouvellement** aux instants  $\phi(n)$  pour avoir



$$\ell \times \sum_{k \geq 1} \sum_{m \geq k} f_{j,j}^{(k)} = \ell \times \sum_{k \geq 1} m f_{j,j}^{(k)} = \ell \times \mu_j = 1$$

d'où

$$\ell = \frac{1}{\mu_j}$$

# Qu'est-ce qu'une chaine de Markov Cachée







## HMM: Hidden Markov Model

- $(X_n)_{n \in \mathbb{N}}$  une chaîne de Markov
- $A$  sa matrice de transition
- $\mathcal{O}$  un ensemble d'observables
- $(vsm_i(\mu))_{i \in Q}$  pour tout  $\mu \in \mathcal{O}$

- Etant donné un modèle  $\theta = (A, vsm)$ , calculer  $P(O|\theta)$ .

ALGORITHME **FORWARD**

- Etant donné  $\theta$  et  $O$ , trouver  $(q_1, \dots, q_n)$  optimal.

ALGORITHME DE **VITERBI**

- Déterminer  $\theta$  à partir d'une observation.

ALGORITHME DE **BAUM-WELCH**

## Idée naïve

$$\begin{aligned} P(O = o_1, \dots, o_T) &= \sum_{(q_1, \dots, q_T) \in Q^T} \prod_{t=1}^T P(o_t | X_t = q_t) \\ &= \sum_{(q_1, \dots, q_T) \in Q^T} \prod_{t=1}^T vsm_{q_t}(o_t) \end{aligned}$$

Problème:  $O(T \times |Q|^T)$


## IProbabilité forward


Etant donné un moment  $t$  et un état  $j$ , on nomme

$$\alpha_t(j) = P(o_1, \dots, o_t, q_t = j)$$

Le résultat viendra par:

$$\begin{aligned} P(O = o_1, \dots, o_T) &= \sum_{j \in Q} P(o_1, \dots, o_T, q_T = j) \\ &= \sum_{j \in Q} \alpha_T(j) \end{aligned}$$






## Relation de récurrence

On a au début

$$\forall j \in Q, \quad \alpha_1(j) = vsm_j(o_1)$$

et  $\forall t \in \llbracket 2, T \rrbracket, \forall j \in Q,$

$$\alpha_t(j) = vsm_j(o_t) \sum_{i \in Q} \alpha_{t-1}(i) a_{ij}$$






# Algorithme de Viterbi

Données:  $A, (vsm_i(\mu))_{j \in Q}, O = (o_1, \dots, o_T)$


Objectif:  $(q_1, \dots, q_T) \in Q^T : P(O | (q_1, \dots, q_T))$  est maximale


Etant donné un moment  $t$  et un état  $j$ , on nomme



$$v_t(j) = \max_{(q_0, \dots, q_{t-1})} P(o_1, \dots, o_t | q_0, \dots, q_{t-1}, q_t = j)$$



$$v_{t+1}(j) = vsm_j(o_t) \times \max_{i \in Q} (v_t(i) a_{ij})$$







## Algorithme de Baum-Welch

On fixe  $Q$  et  $\mathcal{O}$ .

Étant donné une observation  $O = (o_1, \dots, o_T)$ ,  
quel est  $\theta$  maximisant  $P(O|\theta)$ ?

**Probabilité de transition:**

$$a_{ij} = \frac{\text{le nombre de fois où la transition a été faite}}{\text{le nombre de fois où l'on était en } i}$$

**Probabilité d'observation:**

$$vsm_i(o) = \frac{\text{le nombre de fois où l'observation } o \text{ a été faite en } i}{\text{le nombre de fois où l'on était en } i}$$

## Idée:

- Premier modèle « à la main »
- Réestimation via le modèle
- Actualisation

## Condition d'arrêt

$$|P(O|\theta_{n+1}) - P(O|\theta_n)| < \varepsilon$$

## Probabilité backward

Etant donné un moment  $t$  et un état  $j$ , on nomme

$$\beta_t(i) = P(o_{t+1}, \dots, o_T | q_t = i)$$

et comme avec les  $(\alpha_t(i))$ , on a une relation de récurrence

$$\beta_t(i) = \sum_{j=1}^N a_{ij} v_{sm_j}(o_{t+1}) \beta_{t+1}(j) \quad \text{et} \quad \beta_T(i) = a_{iF}$$

On a alors pour tout  $t$ :

$$P(O|\theta) = \sum_{j=1}^N \alpha_t(j) \beta_t(j)$$



On note pour  $t \leq T$ ,  $(i,j) \in Q^2$ ,

$$\zeta_t(i,j) = P(q_t = i, q_{t+1} = j | O, \theta)$$

pour pouvoir ensuite estimer

$$a'_{i,j} = \frac{\sum_{t=1}^T \zeta_t(i,j)}{\sum_{k=1}^N \sum_{t=1}^T \zeta_t(i,k)}$$

# Comment estimer $\zeta_t(i,j)$ ?

## Etapes:

- D'abord

$$P(q_t = i, q_{t+1} = j, O | \lambda) = \alpha_t(i) a_{i,j} v_{sm_j}(o_{t+1}) \beta_t(j)$$

- avec

$$P(A|B,C) = \frac{P(A,B|C)}{P(B|C)}$$

- On obtient:

$$\zeta_t(i,j) = \frac{P(q_t = i, q_{t+1} = j, O | \lambda)}{P(O | \lambda)}$$

- Algorithme **forward**  $\rightarrow P(O | \theta) = \sum_{i=0}^N \alpha_T(i)$

- Finalement

$$\zeta_t(i,j) = \frac{\alpha_t(i) a_{ij} vsm_j(o_{t+1}) \beta_t(j)}{\sum_{i=0}^N \alpha_T(i)}$$

On passe par

$$P(q_t = j | O, \theta) = \frac{P(q_t = j, O | \theta)}{P(O | \theta)} = \frac{\alpha_t(j) \beta_t(j)}{P(O | \theta)}$$

Comme avec  $a_{i,j}$ , pour une observation  $O$ :

$$vsm_j(\nu) = \frac{\sum_{t \text{ tel que } o_t = \nu} P(q_t = j | O, \theta)}{\sum_{t=1}^T P(q_t = j | O, \theta)}$$

# Fonctionnement de l'ADN

Nucléotides: [A, U, C, G]

Brin d'ADN: ACGUAGCUGA

Codon: AUG, CGA, etc...

Protéine: [codon1][codon2]etc...

Problème:

- Début de séquence ?
- Faux départs ?
- Pourquoi une chaîne de Markov Cachée ?




FIG. 13 – *Brin d'ADN*

- Observations: séquence de nucléotides
- Etats cachés: [intron, exon, entrée, sortie]
- Taches:
  - 1) Entraîner notre chaîne de Markov cachée sur un gène
  - 2) Appliquer l'algorithme de Viterbi à de l'ADN du même animal

- **Echantillon d'entraînement:** 4110 nucléotides contenant une partie codante et non codante
- **Echantillon d'essai:** gène de la même espèce précédé d'une centaine de nucléotides (non codants)

*Source: NIH (National Institute of Health)*

- **Constat:**
  - 1) Bon début, arrêt prématuré
  - 2) de nombreux faux départs

- Probabilité de rester consécutivement sur le même état
- Par le théorème ergodique:

$$a_{i,i}^{(n)} \xrightarrow[n \rightarrow \infty]{} \frac{1}{\mu_i}$$



- **Semi-Chaines de Markov**
- **Chaines non homogènes**

```
1  import random as rd
2  def vol_du_joueur(N, p):
3      for _ in range(3):
4          X = [0]
5          Y = [N]
6          temps = 0
7          A = N
8          while A > 0 and A < 2*N:
9              temps += 1
10             if rd.random() < p:
11                 A += 1
12             else:
13                 A -= 1
14             X.append(temps)
15             Y.append(A)
16             plt.plot(X, Y)
17
18     plt.xlabel("temps")
19     plt.ylabel("Pieces")
20     plt.show()
```

```
1 def temps_de_vol(N,p):
2     Y = []
3     nb_essais = 100000
4     for k in range(nb_essais):
5         temps = 0
6         A = N
7         while A > 0 and A < 2*N:
8             temps += 1
9             if rd.random() < p:
10                 A += 1
11             else:
12                 A -= 1
13         Y.append(temps)
14     Yp = [0]*(max(Y)+1)
15     for y in Y:
16         Yp[y] += 1
17     plt.bar(list(range(max(Y)+1)), Yp, width=1.0, edgecolor = "#981FFA")
18     plt.show()
```

```
1 def ruine_du_joueur(N, p, T = 100):
2     ... X_t = np.zeros(2*N+1)
3     ... X_t[N] = 1.0
4     ... T = list(range(1, T))
5     ... A = np.reshape(np.zeros((2*N+1)**2), ((2*N+1), (2*N+1)))
6     ... A[0][0] = 1
7     ... A[-1][-1] = 1
8
9     ... for i in range(1, 2*N):
10         ... A[i][i-1] = 1-p
11         ... A[i][i+1] = p
12
13     ... print(A)
14     ... Argent = []
15     ... for t in T:
16         ... m = max(X_t)
17         ... for k in range(2*N+1):
18             ... if X_t[k] == m:
19                 ... Argent.append(k)
20                 ... break
21         ... X_t = np.dot(X_t, A)
22     ... plt.plot(T, Argent)
```

```
1  ✓ def epidemie_1(temps = 50, population = 10**6):
2      ... propagation = np.array([[0.9, 0.1], [0.3, 0.7]]) # 0 -> infecte, 1 -> sain
3      ... popu = np.array([0, 1])
4      ... X_temps = np.linspace(0, temps, temps)
5      ... Y_infectes = []
6  ✓ ... for t in range(temps):
7      ...     Y_infectes.append(popu[0]*population)
8      ...     popu = np.dot(popu, propagation)
9      ... plt.plot(X_temps, Y_infectes)
```

```
1 def epidemie_2(temps = 100, population = 10**6):
2     propagation = np.array([
3         [0.2, 0.2, 0, 0, 0.0001, 0.0999], # 0 -> infecte vaccine
4         [0.2, 0.8, 0, 0, 0, 0], # 1 -> sain vaccine
5         [0, 0.2, 0.1, 0.7, 0, 0], # 2 -> sain non vaccin
6         [0, 0.2, 0, 0.7, 0.001, 0.099], # 3 -> infecte non vaccine
7         [0, 0, 0, 0, 1, 0], # 4 -> mort
8         [0, 0, 0, 0, 0, 1] # 5 -> immunise
9     ])
10     popu = np.array([0, 0, 1, 0, 0, 0])
11     X_temps = np.linspace(0, temps, temps)
12     Y_infectes = []
13     for t in range(temps):
14         Y_infectes.append(popu[0]*population)
15         popu = np.dot(popu, propagation)
16     plt.plot(X_temps, Y_infectes)
```

```
1 def forward(A, B, Obs):
2     N = len(A)
3     T = len(B)
4     alpha_prec = np.array(B[:, [Obs[0]]])
5     alpha_suiv = np.zeros(N)
6     for t in range(T):
7         nouv_alpha = np.zeros(N)
8         for j in range(N):
9             nouv_alpha[j] = B[j][Obs[t]] * sum(alpha_suiv[i] * A[i][j] for i in range(N))
10        alpha_prec = alpha_suiv[:]
11        alpha_suiv = nouv_alpha[:]
12    return sum(alpha_suiv)
```

# Code

```
1 def Viterbi(A, B, Obs):
2     """# A:matrice de transition
3     """# B:les probabilites d'observation tq b_j(o_t) = B[j][t]
4     """# On travaille avec des logarithmes
5     logA = np.log(A)
6     logB = np.log(B)
7     N = len(A)
8     T = len(Obs)
9     pointeurs = np.reshape(np.zeros(T*N), (N,T)) # sert a retracer le chemin a la fin
10    alpha_prec = np.array(B[:,0][Obs[0]])
11    alpha_suiv = np.zeros(N)
12    for t in range(T):
13        nouv_alpha = np.zeros(N)
14        for j in range(N):
15            nouv_alpha[j], pointeurs[j][t] = max_arg( np.array( np.log(alpha_suiv[i]) + logA[i][j] + logB[j][Obs[t]]
16            """# log est croissante, conserve donc le max
17            """# on met en pointeur l'etat i qui realise le maximum : c'etait l'etat precedent
18            alpha_prec = alpha_suiv[:]
19            alpha_suiv = nouv_alpha[:]
20
21    pmax, i_final = max_arg(alpha_suiv)
22    pmax = np.exp(pmax)
23    etats_successifs = np.zeros(T)
24
25    i = i_final
26    for t in range(1, T+1, -1):
27        etats_successifs[t] = i
28        i = pointeurs[i][t-1]
29    return pmax, etats_successifs
```



```
1 def max_arg(liste):
2     """renvoie le max de la liste et le plus petit indice ou il a ete realise"""
3     m = liste[0]
4     i_max = 0
5     for n in range(len(liste)):
6         if liste[n] > m:
7             m = liste[n]
8             i_max = n
9     return m, i_max
```

```
1 def baum_welch_naif(A, B, Obs):
2     N = len(A)
3     T = len(Obs)
4     alphas = np.reshape(np.zeros(N*T), (T, N))
5     betas = np.reshape(np.zeros(N*T), (T, N))
6     # trouver toutes les valeurs des alphas et betas
7     alphas[:, 0] = B[:, Obs[0]]
8     betas[T-1][:] = np.ones(N)
9
10    for t in range(1, T-2):
11        for j in range(N):
12            alphas[t][j] = B[j][Obs[t]] * sum( alphas[t-1][i] * A[i][j] for i in range(N))
13            betas[T-1-t][j] = B[Obs[T-t]][j] * sum( betas[T-t][i] * A[j][i] for i in range(N))
14
15    Pobs = sum(alphas[T-1][:])
16    # step Expectations
17    zeta = np.reshape(np.zeros(N*N*T), (T, N, N))
18    gamma = np.reshape(np.zeros(N*T), (T, N))
19
```

```

20     for t in range(T-1):
21         for i in range(N):
22             for j in range(N):
23                 zeta[t][i][j] = alphas[t][i] * betas[t+1][j] * A[i][j] * B[Obs[t]][j] / Pobs
24     for t in range(T):
25         for i in range(N):
26             gamma[t][i] = (alphas[t][i] * betas[t][i]) / Pobs
27
28     #step 5
29
30     nouvA = np.reshape(np.zeros(N**2), (N,N))
31     nouvB = np.reshape(np.zeros(N * len(B[0])), (N, len(B[0])))
32
33     for i in range(N):
34         denom = sum( sum( zeta[t][i][k] for k in range(N)) for t in range(T))
35         for j in range(N):
36             nouvA[i][j] = sum( zeta[t][i][j] for t in range(T)) / denom
37
38     for j in range(N):
39         for k in range(len(B)):
40             denom = sum(gamma[t][j] for t in range(T))
41             for t in range(T):
42                 if Obs[t] == k:
43                     nouvB[j][k] = nouvB[j][k] + gamma[t][j] / denom
44
45     return nouvA, nouvB

```

```
1 def traite_fichier_adn():
2     ....nucleotide = open("adn_pur.txt", "r")
3     ....nombres = open("adn_traite", "a")
4     ....lignes = nucleotide.readlines()
5     ....N = ['a', 'c', 't', 'g']
6
7     ....for l in lignes:
8         ....for caract in l:
9             ....if caract == 'a':
10                 ....nombres.write("0 ")
11                 ....if caract == 'c':
12                     ....nombres.write("1 ")
13                     ....if caract == 't':
14                         ....nombres.write("2 ")
15                         ....if caract == 'g':
16                             ....nombres.write("3 ")
17     ....nucleotide.close()
18     ....nombres.close()
19
20     adn = open("adn_traite", "r")
21     sequence = adn.readlines()
22     Ob = []
23     for ligne in sequence:
24         ....for nclt in ligne:
25             ....if nclt in ['0', '1', '2', '3']:
26                 ....Ob.append(int(nclt))
27     adn.close()
```